

Praca projektowa z przedmiotu Sztuczna Inteligencja

Bartłomiej Czajka 169522 2 EF-DI P1

Rzeszów, 2023

Spis treści

1	Opis projektu	2
1.1	Założenia projektowe	2
1.2	Zestaw danych	2
1.3	Przygotowanie danych	3
2	Zagadnienia teoretyczne	3
2.1	Wstęp do sieci neuronowych	3
2.2	Historia sieci neuronowych	4
2.3	Matematyczny opis sztucznego neuronu	5
2.4	Funkcja aktywacji	6
2.5	Sieć głęboka	6
3	Realizacja sieci neuronowej	7
3.1	Opis skryptu	7
4	Eksperymenty	7
4.1	Eksperyment 1	7
4.2	Eksperyment 2	7
4.3	Eksperyment 3	7
5	Wnioski	7

1 Opis projektu

1.1 Założenia projektowe

Celem projektu jest realizacja sieci neuronowej uczonej za pomocą algorytmu sieci głębokiej, klasyfikującej chorobę Parkinsona oraz zbadanie wpływu parametrów sieci na proces uczenia. Projekt został zrealizowany w języku Python z wykorzystaniem biblioteki PyTorch.

1.2 Zestaw danych

Zestaw danych uczących został pobrany ze strony <http://archive.ics.uci.edu/ml/datasets/Parkinsons>. Zawiera on 197 instancji, 23 cechy oraz 2 klasy. Dane są nieuporządkowane, nie ma danych nieokreślonych. Dokładniejszy opis cech zestawu:

- name - Nazwa badanego pacjenta w ASCII i numer nagrania.
- MDVP:Fo(Hz) - Średnia częstotliwość podstawowa głosu.
- MDVP:Fhi(Hz) - Maksymalna częstotliwość podstawowa głosu.
- MDVP:Flo(Hz) - Minimalna częstotliwość podstawowa głosu.

- MDVP:Jitter(%), MDVP:Jitter(Abs), MDVP:RAP, MDVP:PPQ, Jitter:DDP - Kilka miar zmienności częstotliwości podstawowej.
- MDVP:Shimmer, MDVP:Shimmer(dB), Shimmer:APQ3, Shimmer:APQ5, MDVP:APQ, Shimmer:DDA - Kilka miar zmienności amplitudy.
- NHR, HNR - Dwie miary stosunku szumu do składowych tonalnych w głosie.
- status - Stan zdrowia badanego (jeden) - chory na Parkinsona, (zero) - zdrowy.
- RPDE, D2 - Dwie miary złożoności dynamicznej nieliniowej.
- DFA - Wykładnik skalowania fraktalnego sygnału.
- spread1, spread2, PPE - Trzy nieliniowe miary zmienności częstotliwości podstawowej.

1.3 Przygotowanie danych

Sieć ma za zadanie sklasyfikować czy pacjent cierpi na chorobę Parkinsona. Wartość '1' oznacza osobę cierpiącą na chorobę Parkinsona, natomiast '0' oznacza osobę zdrową. Dane zostały uporządkowane i znormalizowane. Normalizacja została wykonana dla każdej obserwacji przy użyciu wzoru:

$$x_{\text{norm}} = \frac{x_{\text{norm_max}} - x_{\text{norm_min}}}{x_{\text{max}} - x_{\text{min}}} \cdot (x - x_{\text{min}}) + x_{\text{norm_min}}$$

gdzie:

- x_{min} - to wektor zawierający minimalne wartości dla każdej obserwacji.
- x_{max} - to wektor zawierający maksymalne wartości dla każdej obserwacji.
- $x_{\text{norm_min}}$ - to wartość minimalna po normalizacji (-1).
- $x_{\text{norm_max}}$ - to wartość maksymalna po normalizacji (1).
- x_{norm} - to macierz zawierająca znormalizowane dane.
- x - to macierz zawierająca dane wejściowe.

2 Zagadnienia teoretyczne

2.1 Wstęp do sieci neuronowych

Sieć neuronowa to jedno z najbardziej fascynujących paradygmatów programowania, jakie kiedykolwiek powstały. W tradycyjnym podejściu do programowania komputerowi nakazujemy, co ma zrobić, dzieląc duże problemy na wiele

mniejszych, precyzyjnie określonych zadań, które komputer może łatwo zrealizować. W przypadku sieci neuronowych nie instruujemy komputera, jak ma rozwiązać nasz problem. Zamiast tego, sieć neuronowa uczy się na podstawie obserwacji danych, tworząc własne rozwiązanie dla danego problemu. Jednakże do roku 2006 nie mieliśmy sposobu na efektywne szkolenie sieci neuronowych, które przewyższałyby bardziej tradycyjne podejścia. To, co zmieniło się w 2006 roku, to odkrycie technik uczenia w tzw. głębokich sieciach neuronowych, znane teraz jako głębokie uczenie. Od tego czasu, głębokie uczenie jest stale rozwijane i obecnie osiąga wybitne wyniki w wielu ważnych dziedzinach, takich jak widzenie komputerowe, rozpoznawanie mowy czy też przetwarzanie języka naturalnego. Są one szeroko wdrażane przez takie firmy jak Google, Microsoft i Facebook. [1]

2.2 Historia sieci neuronowych

Historia sztucznych neuronów sięga lat 40. XX wieku, kiedy Warren McCulloch (neurobiolog) i Walter Pitts (logik) zaproponowali model pierwszego sztucznego neuronu.

Zainspirowany publikacją Warrena McCullocha i Waltera Pittsa, Frank Rosenblatt pracował w latach 50. nad perceptronem, czyli pojedynczą warstwą neuronów zdolną do klasyfikacji obrazów o wielkości kilkuset pikseli. Można to uznać za pierwszego przodka współczesnych sieci neuronowych. Rosenblatt zainspirował się pracami kanadyjskiego psychologa Donalda Hebba, który w swojej książce *Organization of Behavior* w 1949 roku teoretyzował, że połączenia między neuronami (organicznymi) są wzmacniane w miarę ich używania (zostanie to potwierdzone dopiero w latach 60-tych). Pomysł Rosenblatta polegał na powieleniu tego za pomocą jego perceptronu. *New York Times* donosił, że Rosenblatt prorokował, iż perceptrony w przyszłości będą w stanie "rozpoznawać ludzi i wołać ich imiona", "błyskawicznie tłumaczyć mowę w jednym języku na mowę lub pismo w innym języku", "być wystrzeliwane na planety jako mechaniczni eksploratorzy kosmosu", ale także "reprodukować się" i być samoświadome. [3]

Niestety, ze względu na algorytm uczenia, perceptron był ograniczony do pojedynczej warstwy neuronów. Pomimo dużego zainteresowania tymi wczesnymi osiągnięciami, profesorowie MIT Marvin Minsky i Seymour Papert opublikowali w 1969 roku książkę (*Perceptrons: An introduction to computational geometry*) pokazującą, że perceptron miał ograniczone możliwości. Spowodowało to pierwszą "zimę sieci neuronowych" do połowy lat 80. [3]

Paul Werbos, w swojej pracy doktorskiej z 1974 roku, jako pierwszy zaproponował wykorzystanie propagacji wstecznej do optymalizacji sieci neuronowych. Jednak, jako że byliśmy w pierwszej zimie sieci neuronowych, jego praca przeszła niezauważona przez środowisko naukowe. Dopiero później, za sprawą pracy Rumelharta et al. (1986), propagacja wsteczna została spopularyzowana jako technika treningowa dla sieci neuronowych. W szczególności sieci neuronowe zostały wykorzystane do rozpoznawania pisma ręcznego na podstawie techniki zaproponowanej w 1989 roku przez Yanna LeCuna. Jego model został z powodzeniem zaimplementowany, kończąc na odczytywaniu cyfr napisanych ręcznie


w około 10 do 20% wszystkich czeków przetwarzanych w USA. Niemniej jednak wkrótce pojawił się nowy problem, powodujący, że uczenie stawało się powolne i niestabilne. W miarę jak sieci neuronowe stawały się coraz głębsze (z większą liczbą warstw), wsteczna propagacja stawała się wolniejsza (problem zanikającego gradientu). [3]

Na początku lat 2010, wiele badań zalecało użycie określonej funkcji aktywacji (ReLU) w neuronach do przekazywania informacji. To, wraz z lepszymi algorytmami optymalizacji (takimi jak ADAM), pomogło w efektywnym trenowaniu głębszych sieci neuronowych. [3]

W ostatnich latach dokonano znaczącego postępu w dziedzinie sztucznej inteligencji. Przykłady sztucznej inteligencji takie jak AlphaGo i GPT-3 wykazały zdolność do osiągnięcia wyjątkowych wyników w dziedzinach gier planszowych i generowania tekstów. Jednak to tylko początek. W przyszłości możemy spodziewać się dalszego rozwoju sztucznej inteligencji, która będzie coraz bardziej zaawansowana i wszechstronna. Sztuczna inteligencja ma potencjał do rewolucjonizowania różnych dziedzin, takich jak medycyna, przemysł, transport czy badania naukowe. Jej zdolność do szybkiego uczenia się, analizowania ogromnych ilości danych i podejmowania złożonych decyzji otwiera nowe możliwości i perspektywy.

2.3 Matematyczny opis sztucznego neuronu

Podstawowym elementem budującym strukturę sieci neuronowej jest neuron. Jest to element, który przetwarza informacje. W pewnym, uproszczonym stopniu jest wzorowany na funkcjonowaniu biologicznej komórki nerwowej. Struktura neuronu zawiera wiele wejść oraz jedno wyjście. Jednym z najważniejszych składników neuronu są wagi, których wartości decydują o zachowaniu neuronu. Są one zazwyczaj ustalane w trakcie procesu uczenia.



Rysunek 1: Model neuronu [4]

Każdy pojedynczy neuron przyjmuje sygnały wejściowe, które są następnie przetwarzane. Każde wejście ma przypisany współczynnik wagowy, który określa jak bardzo wpływa ono na wynik neuronu. Dodatkowo, neuron posiada "bias", czyli dodatkowe wejście, na którym występuje stała wartość. Wszystkie te informacje są sumowane, gdzie jest obliczane łączne pobudzenie neuronu. Następnie wartość pobudzenia przechodzi przez funkcję aktywacji, która określa sygnał wyjściowy neuronu dany wzorem:

$$y = \sum_{j=1}^L f(w_j x_j + b)$$

gdzie:

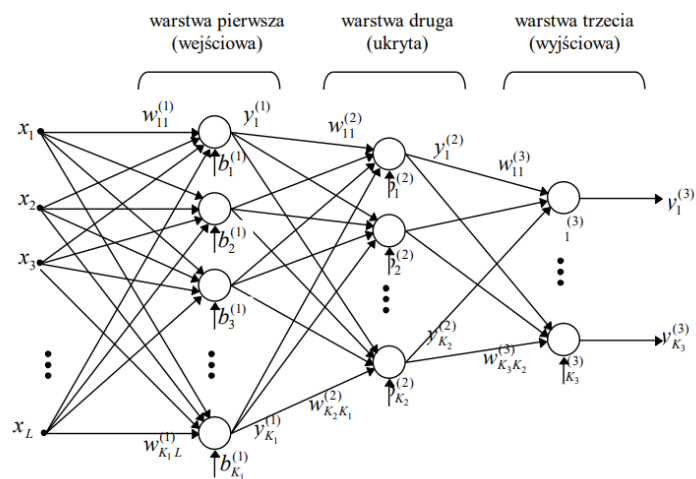
- j – indeks, który przyjmuje wartości od 1 do L ,
- y – wyjście neuronu,
- w_j – współczynnik wagowy przypisany do j -tego wejścia,
- x_j – j -ty sygnał wejściowy,
- b – bias [2].

2.4 Funkcja aktywacji

2.5 Sieć głęboka

Sieci głębokie to rodzaj modeli uczenia maszynowego, które składają się z wielu warstw neuronów, zwanych warstwami głębokimi. Każda warstwa wykonuje operacje na danych wejściowych, a następnie przekazuje wyniki do kolejnej warstwy, aż do warstwy wyjściowej, która generuje ostateczne predykcje lub wyniki.

Warstwa sieci głębokiej składa się z macierzy wag (w), wektora przesunięć (b), funkcji aktywacji (f) oraz wektora sygnałów na wyjściu warstwy (y).



Rysunek 2: Sieć wielowarstwowa jednokierunkowa [4]

3 Realizacja sieci neuronowej

3.1 Opis skryptu

4 Eksperymenty

4.1 Eksperyment 1

4.2 Eksperyment 2

4.3 Eksperyment 3

5 Wnioski

Literatura

- [1] Michael Nielsen, *Neural Networks and Deep Learning*. Determination Press, 2015.
- [2] Ryszard Tadeusiewicz, Maciej Szaleniec, *Leksykon sieci neuronowych*. Wrocław, 2015.
- [3] Nicolas Vandeput, *A Brief History Of Neural Networks*, [dostęp: 15.05.2023].
- [4] Zajdel R., *Ćwiczenie 4 Model Neuronu*, Rzeszów, KLiA, PRz.

- [5] Zajdel R., *Procedura przygotowania danych dla sieci neuronowych na potrzeby projektu z modułu sztuczna inteligencja - Listing1*, Rzeszów, KLiA, PRz.
- [6] Zajdel R., *Procedura przygotowania danych dla sieci neuronowych na potrzeby projektu z modułu sztuczna inteligencja - Listing2*, Rzeszów, KLiA, PRz.